TECH CHALLENGE - FASE 2

Otimização de modelos de diagnóstico de câncer de mama com algoritmos genéticos e LLMs

Relatório técnico - Projeto 1: otimização de modelos de diagnóstico

Gabriel Wesley — RM376899

Gustavo Leite — RM375733

Luiz Fellipe — RM376854

Repositório: https://github.com/Gusta2150/desafio_tech_2

30/10/2026

Resumo executivo

Este relatório descreve a Fase 2 do Tech Challenge (Projeto 1 - otimização de modelos de diagnóstico). Partindo dos modelos de classificação de câncer de mama da Fase 1 (Regressão Logística e Random Forest sobre o dataset Breast Cancer Wisconsin), implementamos do zero um algoritmo genético para otimizar seus hiperparâmetros - incluindo o limiar de decisão - e integramos uma LLM pré-treinada para explicar os resultados em linguagem natural para médicos.

Foram executados 5 experimentos com configurações diferentes do AG para cada modelo, além de uma busca aleatória com o mesmo orçamento. O modelo selecionado foi a **Regressão Logística** otimizada no experimento **E1_pop_pequena**. No mesmo conjunto de teste da Fase 1 (114 pacientes, 42 malignas), o recall de malignidade foi de 95,2% para 97,6% e os falsos negativos de 2 para 1, com F1 de 0,964 -> 0,965 e ROC-AUC de 0,995 -> 0,997.

Como o teste tem poucos casos malignos, também medimos o desempenho por validação cruzada repetida (5x3) no treino: o fitness passou de 0,9659 +/- 0,0241 para 0,9703 +/- 0,0177. A seção 6 discute o tamanho real do ganho.

1. Contexto e objetivo

Na Fase 1 o grupo construiu um pipeline de machine learning (com notebook, API FastAPI e frontend Angular) que classifica massas mamárias como benignas ou malignas a partir de 30 medidas morfológicas de núcleos celulares (raio, textura, perímetro, área, concavidade etc., em média, erro-padrão e pior valor). Os modelos usavam hiperparâmetros fixos escolhidos manualmente e limiar de 0,5.

Objetivos desta fase:

- Otimizar os hiperparâmetros dos modelos da Fase 1 com um algoritmo genético (codificação, seleção, cruzamento, mutação e fitness baseada em métricas clínicas).
- Comparar os modelos otimizados com os originais e realizar pelo menos 3 experimentos com configurações diferentes do AG.
- Integrar uma LLM pré-treinada para gerar explicações dos diagnósticos e transformar métricas em insights para médicos, com prompt engineering e avaliação de qualidade.
- Preparar a solução para produção: API, monitoramento, logging e escalabilidade automática.

2. Dados e protocolo experimental

Usamos o mesmo arquivo e as mesmas regras de limpeza da Fase 1 (remoção de *id* e da coluna vazia, rótulos M/B -> 1/0) e o mesmo split estratificado 80/20 com *random_state=42*: 455 amostras de treino (170 malignas) e 114 de teste (42 malignas). Manter o split idêntico garante que a comparação com a Fase 1 seja justa.

Para evitar vazamento de informação, o protocolo separa claramente busca e avaliação:

- O AG só enxerga o conjunto de treino: cada indivíduo é avaliado por validação cruzada estratificada 5-fold.
- O melhor indivíduo de cada experimento é re-treinado em todo o treino e avaliado (a) no teste hold-out da Fase 1 e (b) numa validação cruzada repetida 5x3 com outra semente (2026).
- O modelo publicado na API é escolhido pela validação repetida - nunca pelo teste.

3. Algoritmo genético

3.1 Codificação (representação dos genes)

Cada indivíduo é um vetor real x em [0, 1]^d. Cada posição é um gene, decodificado conforme o tipo do hiperparâmetro: genes reais (com escala logarítmica para parâmetros multiplicativos como C), inteiros (arredondamento) e categóricos (o intervalo [0, 1) é dividido em faixas iguais, uma por categoria). Com essa representação os mesmos operadores servem para qualquer modelo, e podemos usar operadores próprios de codificação real, como BLX-alfa e mutação gaussiana.

Regressão Logística - 4 genes:

Gene	Tipo	Domínio
C	real (escala log)	[0,001, 100]
l1_ratio	real	[0, 1]
class_weight	categórico	None, balanced
threshold	real	[0,2, 0,8]

Random Forest - 9 genes:

Gene	Tipo	Domínio
n_estimators	inteiro	[50, 300]
max_depth	categórico	3, 5, 8, 12, 20, None
min_samples_split	inteiro	[2, 20]
min_samples_leaf	inteiro	[1, 10]
max_features	categórico	sqrt, log2, 0,3, 0,5, 0,8
criterion	categórico	gini, entropy
class_weight	categórico	None, balanced, balanced_subsample
bootstrap	categórico	True, False
threshold	real	[0,2, 0,8]

O **limiar de decisão** é um gene nos dois modelos. Na triagem de câncer um falso negativo (caso maligno não sinalizado) é muito mais grave que um falso positivo, e o limiar é o controle mais direto desse equilíbrio - na Fase 1 ele estava fixo em 0,5. No Random Forest, n_estimators vai até 300 (a Fase 1 usava 500) para caber no orçamento computacional; a curva de ganho de árvores adicionais é bem plana nessa faixa.

3.2 Operadores

Etapa	Operadores implementados	Papel
Seleção	Torneio (k=3), roleta (com deslocamento pelo mínimo), ranking linear	Escolher pais; k e o tipo controlam a pressão seletiva
Cruzamento	Uniforme, um ponto, BLX-alfa (alfa=0,5)	Combinar boas soluções; BLX-alfa explora além dos pais
Mutação	Gaussiana (σ configurável), uniforme (reinicialização)	Manter diversidade; gaussiana faz ajuste fino, uniforme explora
Elitismo	Os n melhores passam intactos	Garante que o melhor fitness nunca piora
Outros	Cache de fitness, parada antecipada, semeadura com o modelo original	Economia de treinos e convergência controlada

A roleta usa o fitness deslocado pelo mínimo da população: como os valores ficam muito próximos (0,95-0,98), a roleta pura seria quase aleatória.

3.3 Função fitness

fitness = 0,45 - Recall(maligno) + 0,35 - F1(maligno) + 0,20 - ROC-AUC, calculado sobre as probabilidades out-of-fold da CV 5-fold no treino.

- **Recall** tem o maior peso: é a métrica que a Fase 1 já priorizava (não deixar passar casos malignos).
- **F1** impede a solução degenerada "tudo é maligno" (recall 1,0 com precisão baixa), que um limiar muito baixo produziria.
- **ROC-AUC** mede a qualidade da ordenação das probabilidades, independente do limiar.
- Indivíduos que só diferem no limiar reaproveitam as probabilidades já calculadas (sem re-treinar) e indivíduos repetidos vêm do cache - o que reduz bastante o custo, principalmente no Random Forest.

4. Experimentos

Experimento	Pop.	Ger.	Seleção	Crossover	Mutação	Elite	Observação
E1_pop_pequena	10	8	tournament	uniform (0,9)	gaussian (0,10)	1	
E2_blx_torneio	16	12	tournament	blx (0,9)	gaussian (0,15)	2	

Experimento	Pop.	Ger.	Seleção	Crossover	Mutação	Elite	Observação
E3_roleta_um_ponto	24	10	roulette	one_point (0,8)	gaussian (0,05)	2	
E4_alta_mutacao	16	12	rank	uniform (0,7)	uniform (0,30)	2	
E5_semeado_baseline	16	12	tournament	blx (0,9)	gaussian (0,15)	2	semeado c/ original; parada em 6

Todos os experimentos usam a mesma semente (42), a mesma fitness e as mesmas dobras de CV, para que as diferenças venham apenas da configuração do AG.

4.1 Resultados - Regressão Logística

Configuração	Fitness CV	CV 5x3 (média +/- dp)	Recall teste	F1 teste	AUC teste	FN	FP	Avaliações	Tempo (s)
Original (Fase 1)	0,9671	0,9659 +/- 0,0241	95,2%	0,964	0,995	2	1	-	-
E1_pop_pequena	0,9771	0,9703 +/- 0,0177	97,6%	0,965	0,997	1	2	36	8
E2_blx_torneio	0,9770	0,9699 +/- 0,0198	95,2%	0,952	0,994	2	2	158	55
E3_roleta_um_ponto	0,9780	0,9678 +/- 0,0185	97,6%	0,943	0,997	1	4	145	34
E4_alta_mutacao	0,9763	0,9694 +/- 0,0211	97,6%	0,976	0,997	1	1	148	51
E5_semeado_baseline	0,9770	0,9699 +/- 0,0198	95,2%	0,952	0,994	2	2	158	56
Busca aleatória	0,9763	0,9703 +/- 0,0195	97,6%	0,976	0,997	1	1	158	52

Melhor configuração pela validação repetida: **E1_pop_pequena**. Hiperparâmetros encontrados: C = 0,5928; l1_ratio = 0,11; class_weight = None; threshold = 0,26. Originais: C = 1; l1_ratio = 0; class_weight = balanced; threshold = 0,5.

4.2 Resultados - Random Forest

Configuração	Fitness CV	CV 5x3 (média +/- dp)	Recall teste	F1 teste	AUC teste	FN	FP	Avaliações	Tempo (s)
Original (Fase 1)	0,9621	0,9516 +/- 0,0298	92,9%	0,963	0,997	3	0	-	-
E1_pop_pequena	0,9676	0,9606 +/- 0,0195	92,9%	0,951	0,998	3	1	51	144
E2_blx_torneio	0,9659	0,9579 +/- 0,0276	92,9%	0,951	0,996	3	1	169	307
E3_roleta_um_ponto	0,9674	0,9567 +/- 0,0246	92,9%	0,963	0,995	3	0	162	363
E4_alta_mutacao	0,9663	0,9613 +/- 0,0256	95,2%	0,976	0,998	2	0	177	474
E5_semeado_baseline	0,9650	0,9570 +/- 0,0271	92,9%	0,951	0,998	3	1	108	313
Busca aleatória	0,9640	0,9534 +/- 0,0231	92,9%	0,963	0,997	3	0	169	469

Melhor configuração pela validação repetida: **E4_alta_mutacao**. Hiperparâmetros encontrados: n_estimators = 65; max_depth = 8; min_samples_split = 5; min_samples_leaf = 2; max_features = sqrt; criterion = entropy; class_weight = None; bootstrap = False; threshold = 0,41. Originais: n_estimators = 500; max_depth = None; min_samples_split = 2; min_samples_leaf = 2; max_features = sqrt; criterion = gini; class_weight = balanced; bootstrap = True; threshold = 0,5.

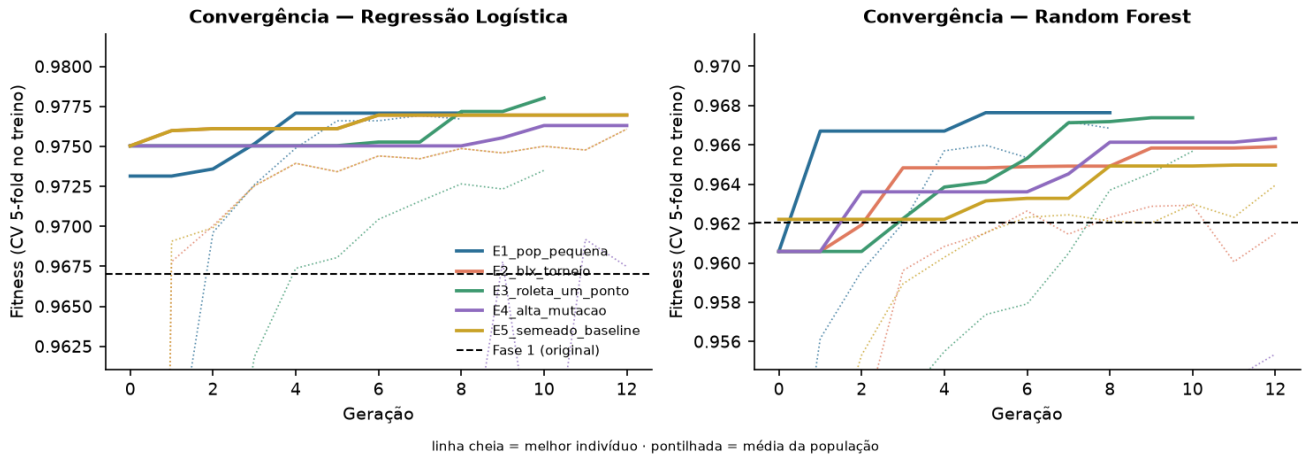


Figura 1 - Convergência: melhor indivíduo (linha cheia) e média da população (pontilhada) por geração. A linha tracejada é o fitness do modelo original.

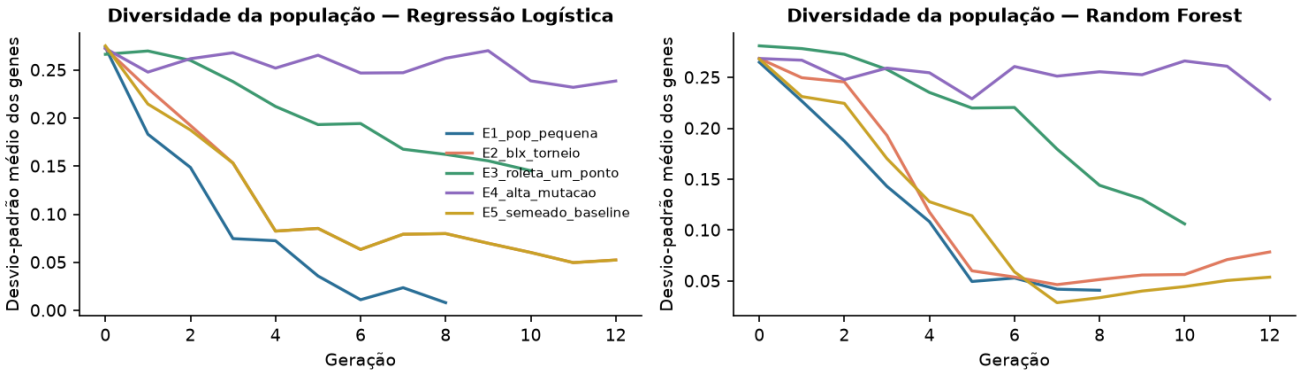


Figura 2 - Diversidade da população (desvio-padrão médio dos genes).

4.3 Análise dos experimentos

- **Regressão Logística**: todos os experimentos superaram o fitness do modelo original (0,9671) já nas primeiras gerações. O maior fitness de CV foi do E3_roleta_um_ponto (0,9780); o E1_pop_pequena chegou a 0,9771 com apenas 36 avaliações.
- **Random Forest**: todos os experimentos superaram o fitness do modelo original (0,9621) já nas primeiras gerações. O maior fitness de CV foi do E1_pop_pequena (0,9676); o E1_pop_pequena chegou a 0,9676 com apenas 51 avaliações.
- **Pressão seletiva e diversidade** (Figura 2): com torneio (E1_pop_pequena, E2_blx_torneio, E5_semeado_baseline) a população converge rápido - no E1_pop_pequena a diversidade final ficou em 0,01-0,04. A roleta (E3_roleta_um_ponto), mesmo com mutação baixa, manteve diversidade 0,11-0,15 no fim: como os fitness são muito próximos, ela seleciona quase uniformemente. A mutação alta e uniforme com ranking (E4_alta_mutacao) manteve a maior diversidade (0,23-0,24), o que evita convergência prematura, mas deixa a média da população mais baixa e ruidosa (Figura 1).
- **Tamanho da população e orçamento**: o E1_pop_pequena, com a menor população e o menor número de avaliações, chegou a resultados comparáveis aos experimentos maiores. Com a fitness quase saturada (~0,97) e espaços de busca pequenos, mais avaliações rendem ganhos marginais - as diferenças entre experimentos ficam dentro do desvio-padrão da validação repetida.
- **Semeadura (E5)**: colocar o modelo original na população inicial não trouxe vantagem. Na Regressão Logística o resultado foi idêntico ao E2 (mesma configuração sem semente): o original é superado logo na primeira geração e a busca segue o mesmo caminho. No Random Forest ficou abaixo do E2 - a semente pode atrair a busca para a vizinhança da solução manual.
- **Cache**: somando todos os experimentos, foram 1312 avaliações de fitness, mas só 1147 combinações de hiperparâmetros precisaram ser treinadas (CV 5-fold) - indivíduos repetidos e variações apenas do limiar reaproveitam resultados.

5. Comparativo: modelos originais x otimizados

Modelo	Versão	Acurácia	Precisão	Recall	F1	ROC-AUC	FN	FP
Regressão Logística	Original	97,4%	97,6%	95,2%	0,964	0,995	2	1
Regressão Logística	AG (E1_pop_pequena)	97,4%	95,3%	97,6%	0,965	0,997	1	2
Random Forest	Original	97,4%	100,0%	92,9%	0,963	0,997	3	0
Random Forest	AG (E4_alta_mutacao)	98,2%	100,0%	95,2%	0,976	0,998	2	0

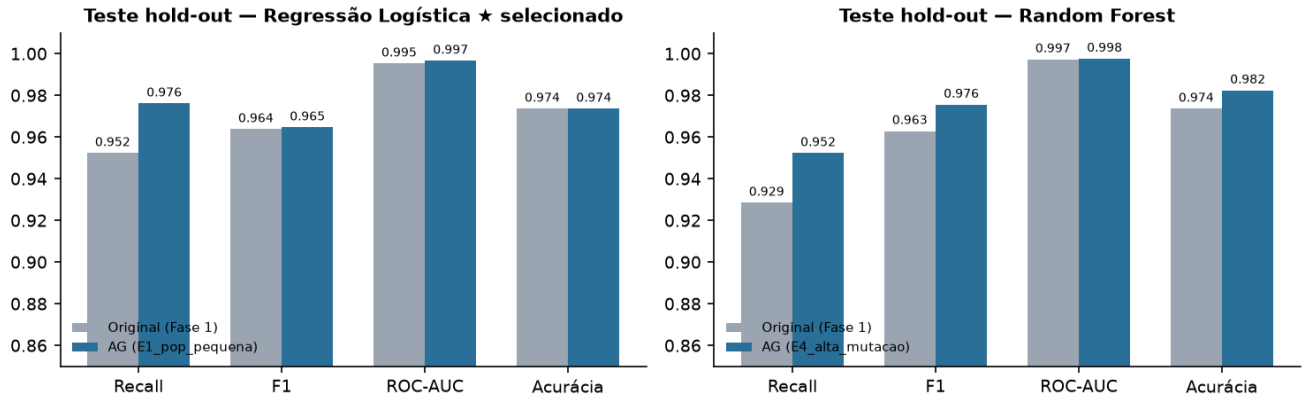


Figura 3 - Métricas no teste hold-out da Fase 1 (114 amostras).

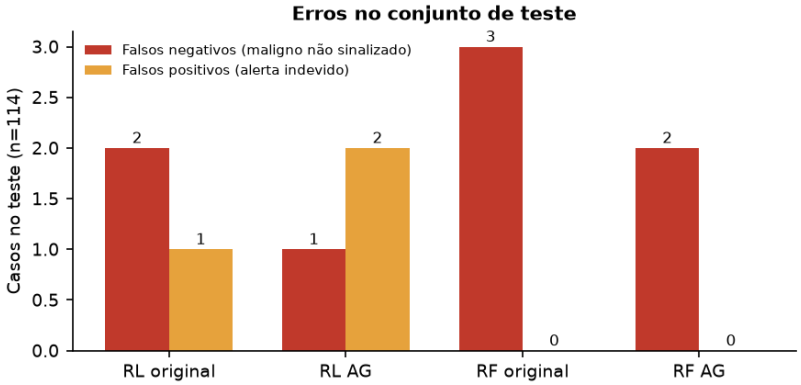


Figura 4 - Falsos negativos e falsos positivos no teste (RL = Regressão Logística, RF = Random Forest).

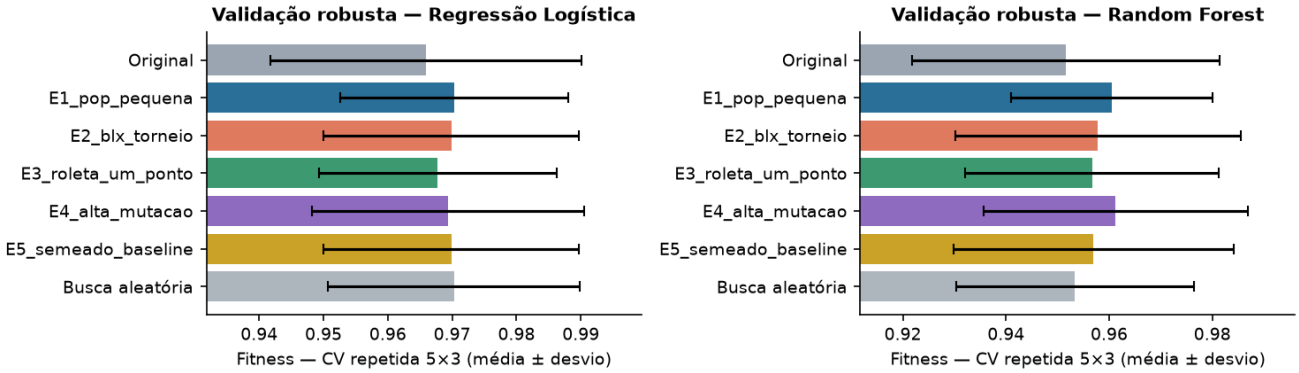


Figura 5 - Fitness na validação cruzada repetida 5x3 (média +/- desvio).

5.1 Comparação com outra abordagem: busca aleatória

Para verificar se o AG agrega valor além de testar muitas combinações, comparamos cada modelo com uma busca aleatória que recebe o mesmo número de avaliações do experimento E2. Regressão Logística: AG (E2_blx_torneio) 0,9770 x busca aleatória 0,9763 com 158 avaliações. Random Forest: AG (E2_blx_torneio) 0,9659 x busca aleatória 0,9640 com 169 avaliações.

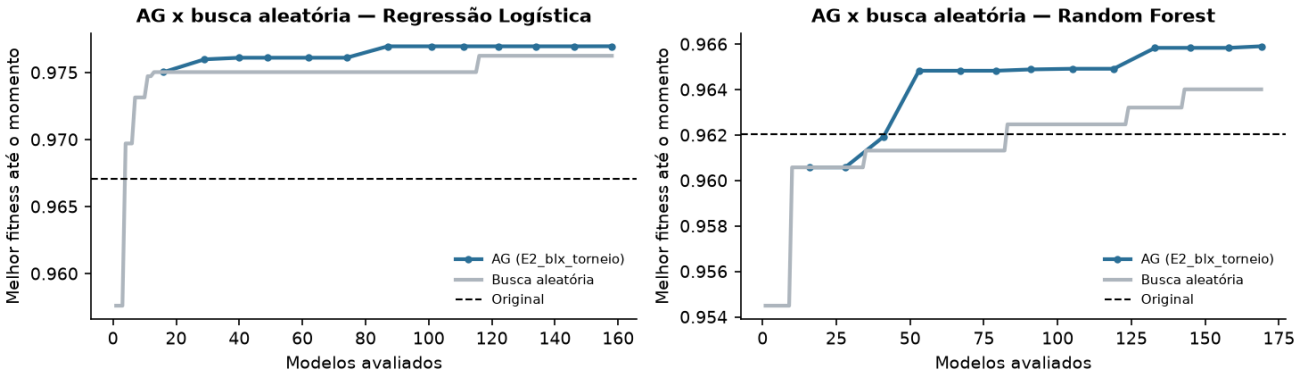


Figura 6 - Melhor fitness encontrado em função do número de modelos avaliados: AG x busca aleatória.

Neste espaço de busca relativamente pequeno (4 e 9 genes) e com fitness quase saturada (~0,97), a vantagem do AG sobre a busca aleatória é pequena; ela tende a crescer com espaços maiores (mais modelos, seleção de atributos), que são o próximo passo natural.

6. Discussão do ganho

O ganho veio principalmente de dois fatores: (1) o **limiar de decisão** - o AG escolheu 0,26 em vez de 0,5, deslocando o ponto de operação para capturar mais casos malignos - e (2) a **regularização**/estrutura do modelo. A diferença de falsos negativos no teste (2 -> 1) é clinicamente relevante, mas o teste tem apenas 42 casos malignos: cada caso equivale a 2,4% de recall. Por isso reportamos também a CV repetida, em que as diferenças são menores e os desvios-padrão se sobrepõem parcialmente - o ganho é consistente na direção, mas modesto em magnitude, o que é esperado num dataset em que o modelo original já tinha ROC-AUC ~ 0,99.

O custo do ganho em recall é visível nos falsos positivos (1 -> 2 no teste). Em triagem, um alerta indevido gera um exame adicional; um falso negativo pode atrasar o diagnóstico de um câncer - a fitness foi desenhada para refletir essa assimetria. Os pesos da fitness são configuráveis em configs/experiments.yaml e devem ser validados com a equipe clínica.

7. Integração com LLM

7.1 Abordagem

A LLM não acessa o modelo nem os dados brutos. Para cada paciente, a API monta um **contexto estruturado (grounding)** com: probabilidade de malignidade, limiar, faixa de risco, os 5 fatores que mais pesaram *para aquela paciente* (com o valor dela e as médias de benignos e malignos no treino) e o desempenho do modelo no teste. Os fatores locais são calculados por **oclusão**: cada atributo é substituído pela mediana do treino e mede-se quanto a probabilidade muda - método agnóstico ao modelo, sem depender do SHAP.

- **Explicação de casos** (/interpret): resumo, fatores relevantes, confiabilidade, recomendação, limitações e aviso, em JSON.
- **Insights de desempenho** (/report/performance): traduz a comparação original x otimizado (recall, falsos negativos etc.) em impacto clínico para a equipe.
- **Perguntas livres** (/ask): o(a) médico(a) pergunta em linguagem natural sobre o caso - base para a integração com dados textuais do Módulo 3.
- **Provedores plugáveis**: qualquer API compatível com OpenAI (GPT-OSS 120B via Groq, LLaMA via Ollama local, GPT, LM Studio) e a API da Anthropic, configurados por variáveis de ambiente. O padrão é o Groq com openai/gpt-oss-120b (o Groq descontinuou o LLaMA 3.3 70B); como é um modelo de raciocínio, usa reasoning_effort=low para o raciocínio não consumir os tokens da resposta JSON.
- **Limite de taxa**: respostas 429 e erros temporários são repetidos respeitando o Retry-After da API; uma avaliação com falhas de API é salva à parte e nunca entra neste relatório.
- **Fallback**: se a LLM falha ou responde fora do formato, a API devolve uma explicação por template e registra o evento na métrica llm_requests_total{status="fallback"}.

7.2 Prompt engineering

Técnica	Como foi aplicada	Objetivo
Persona e público	Assistente de apoio à decisão para mastologistas e patologistas	Vocabulário e nível técnico adequados
Grounding	Todos os números vêm do CONTEXTO em JSON	Evitar números inventados
Restrições de segurança	Proibido diagnóstico definitivo; aviso obrigatório	Uso responsável em saúde
Saída estruturada	Esquema JSON com campos fixos	Exibir no frontend e validar
Few-shot	Um par contexto -> resposta completo	Tom, tamanho e forma de citar fatores
Autoverificação	Checklist silencioso antes de responder	Coerência com o limiar e números
Temperatura 0,2	Parâmetro da chamada	Respostas estáveis

Três estratégias foram comparadas: **basico** (zero-shot, sem regras), **estruturado** (persona + regras + JSON) e **few_shot** (estruturado + exemplo + autoverificação). Trecho do prompt de sistema usado nas estratégias estruturado e few_shot:

```
Você é um assistente de apoio à decisão clínica em um hospital universitário.
Seu público são médicos(as) mastologistas e patologistas. Você explica, em português do Brasil,
o resultado de um modelo de machine learning que estima a probabilidade de malignidade de uma
massa mamária a partir de medidas morfológicas de núcleos celulares (exame de PAAF digitalizado).

Regras obrigatórias:
1. Use SOMENTE os números presentes no CONTEXTO. Não invente valores, percentuais ou estatísticas.
2. Nunca afirme diagnóstico definitivo. Não use expressões como "confirma câncer", "é maligno",
   "descarta câncer" ou "não há câncer". Fale em probabilidade estimada e sinal de alerta.
3. Cite os fatores pelo nome em português e compare o valor da paciente com as médias de
   casos benignos e malignos quando isso ajudar a interpretação.
4. Seja objetivo: frases curtas, sem jargão de computação (evite "feature", "pipeline", "threshold").
5. Termine sempre com o aviso de que se trata de apoio à decisão e não substitui avaliação médica.
6. Responda apenas com um objeto JSON válido.
```

7.3 Avaliação da qualidade

Critério	Como é medido
formato	JSON válido com todos os campos esperados
fidelidade	Fração dos números citados que existem no contexto (detecta alucinação numérica)
cobertura	Fração dos 3 fatores principais mencionados
coerencia	Texto descreve o risco na mesma direção da classificação (acima/abaixo do limiar)
seguranca	Tem aviso de apoio à decisão e não usa linguagem de diagnóstico definitivo
legibilidade	Tamanho médio das frases (<= 25 palavras = 1)
juiz (opcional)	Outra LLM dá notas 1-5 para clareza, utilidade clínica, fidelidade e segurança

Resultados com **groq / openai/gpt-oss-120b** em 10 casos do teste (erros do modelo, casos próximos ao limiar e casos típicos de cada classe):

Estratégia	formato	fidelidade	cobertura	coerencia	seguranca	legibilidade	score_geral	juiz (1-5)	latência (s)
basico	0,00	0,98	1,00	1,00	0,50	1,00	0,75	4,78	7,28
estruturado	1,00	1,00	0,93	1,00	1,00	1,00	0,99	4,65	9,75
few_shot	1,00	1,00	0,90	1,00	1,00	1,00	0,98	4,53	18,23

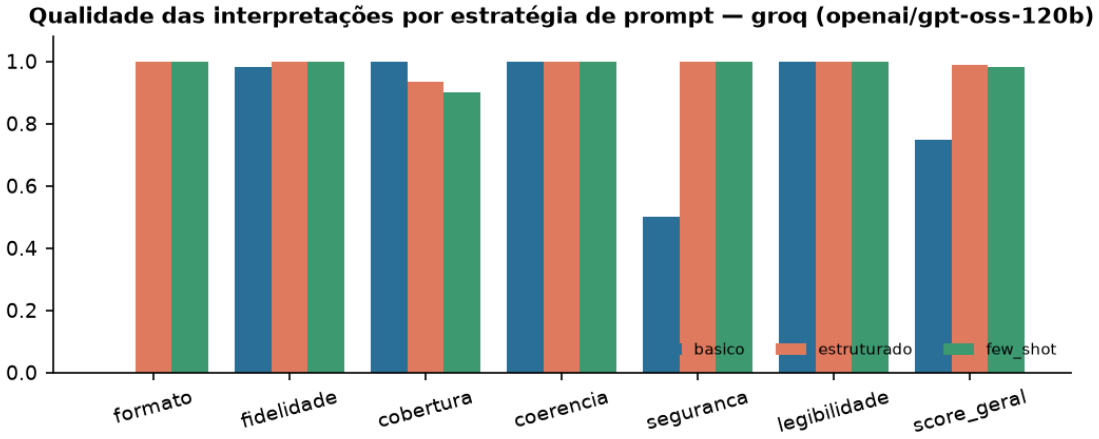


Figura 7 - Qualidade das interpretações por estratégia de prompt.

O prompt básico teve score geral 0,75, contra 0,98 do few-shot: sem regras e sem formato, a LLM tende a omitir o aviso, a não produzir JSON e a usar números que não estão no contexto.

Exemplo de explicação gerada (estratégia few_shot):

```
Resumo: O modelo estimou probabilidade de malignidade de 46.0%, acima do limiar de decisão de 0.26, colocando a
amostra na faixa de risco moderado.

Fatores relevantes:
• Textura (pior valor) de 41.61, acima da média de malignos (29.5743) - aumenta o risco.
• Textura (média) de 30.72, acima da média de malignos (21.7129) - aumenta o risco.
• Simetria (pior valor) de 0.2196, abaixo da média de benignos (0.2706) - reduz o risco.

Confiabilidade: No teste, o modelo alcançou recall de 97.6% e identificou 1 falso negativo em 114 amostras, com
precisão de 95.3%.

Recomendação: Considerar avaliação clínica detalhada e, se indicado, confirmação histopatológica, sempre baseada no
julgamento do médico.

Limitações: O modelo não incorpora histórico clínico, exame físico nem achados de imagem.

Aviso: Apoio à decisão: não confirma nem descarta câncer e não substitui a avaliação médica.
```

Exemplo de insights de desempenho para a equipe clínica (/report/performance):

```
Resumo: O modelo otimizado aumentou o recall de 95,2% para 97,6% reduzindo falsos negativos de 2 para 1, mas a
precisão caiu de 97,6% para 95,3% aumentando falsos positivos de 1 para 2; a acurácia permaneceu em 97,4% e o ROC AUC
subiu de 0,995 para 0,997.

Insights:
• Com 114 pacientes de teste, o modelo otimizado deixou de perder apenas 1 caso maligno (falso negativo) contra 2 do
original, o que pode salvar um paciente que poderia ter sido subtratado.
• A elevação do recall de 95,2% para 97,6% significa que 40 dos 42 casos malignos foram identificados pelo modelo
otimizado, comparado a 38 pelo original.
• A queda na precisão de 97,6% para 95,3% gera um aumento de falsos positivos de 1 para 2, ou seja, duas pacientes
saudáveis podem ser encaminhadas para exames adicionais que antes não seriam.
• O ROC AUC melhorou marginalmente de 0,995 para 0,997, indicando que a capacidade discriminatória do modelo está
praticamente saturada.
• A mudança no threshold de 0,5 para 0,26 foi decisiva para melhorar a sensibilidade, mas requer atenção ao balancear
o número de exames desnecessários.

Impacto clínico: A redução de um falso negativo pode significar a detecção precoce de um câncer que, de outra forma,
teria sido perdido, potencialmente melhorando o prognóstico; porém, o pequeno aumento de falsos positivos pode
sobrecarregar o serviço de diagnóstico com exames adicionais sem grande benefício clínico.

Recomendação: Realizar validação externa em uma coorte maior, analisar o custo-benefício dos falsos positivos
adicionais e ajustar o threshold conforme a capacidade de triagem do hospital antes da implementação rotineira.

Aviso: Os resultados são baseados em apenas 114 amostras de teste, com 42 casos malignos; a variação estatística pode
ser alta e o desempenho pode mudar em populações diferentes.
```

Conferência (calculada dos resultados, não pela LLM): no teste, o modelo original detecta 40 de 42 casos malignos e o otimizado, 41 de 42; falsos positivos 1 -> 2. Contagens derivadas que a LLM escreve ("x de y casos") precisam de revisão humana: o critério de fidelidade só verifica se cada número existe no contexto, não se a conta está certa.

8. Arquitetura, escalabilidade e monitoramento

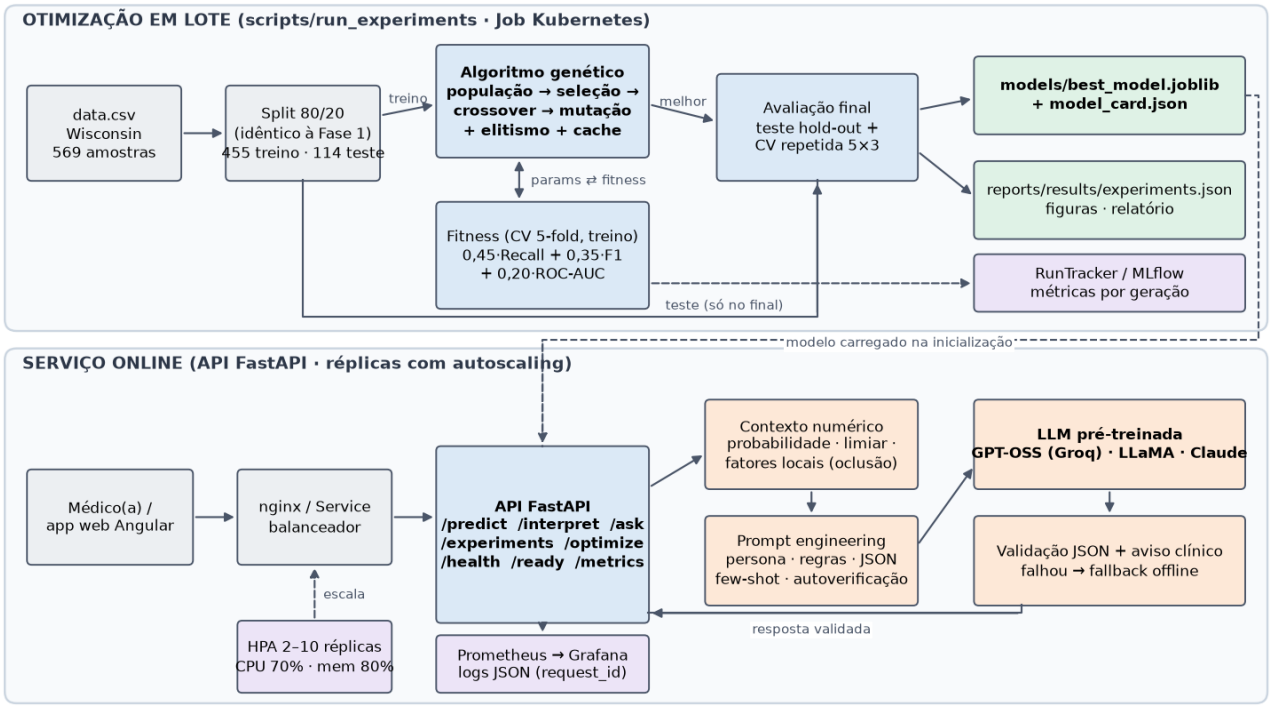


Figura 8 - Arquitetura da solução.

- **API sem estado** (FastAPI): o modelo é lido de models/best_model.joblib na inicialização; qualquer réplica atende qualquer requisição.
- **Escala local**: docker compose up --scale api=N, com nginx re-resolvendo o DNS das réplicas a cada 10 s.
- **Escala automática** (deploy/k8s/api.yaml): HorizontalPodAutoscaler de 2 a 10 réplicas por CPU (70%) e memória (80%), subida rápida (30 s) e descida lenta (5 min) para evitar oscilação; readiness/liveness probes, rolling update sem indisponibilidade e PodDisruptionBudget.
- **Otimização em lote** (deploy/k8s/ga-job.yaml): o AG roda como Job indexado, um pod por modelo, sem competir com a API. A rota /optimize existe para demonstração (no máximo 1 job por réplica).
- **Monitoramento**: métricas Prometheus em /metrics (volume e latência por rota, requisições em andamento, distribuição das probabilidades previstas para detectar drift, chamadas/latência/fallback da LLM, jobs do AG e melhor fitness) e Grafana no docker-compose.
- **Logging**: logs JSON estruturados com request_id propagado (cabeçalho x-request-id).
- **Rastreamento de experimentos**: cada execução do AG grava parâmetros, métricas por geração e resultado em reports/runs/ e, se MLFLOW_TRACKING_URI estiver definida, também no MLflow.
- **Aplicação web** (frontend/, Angular): mostra a convergência do AG e uma execução ao vivo, a jornada do médico (paciente, previsão, explicação, pergunta livre), um inspetor com tudo o que entra e sai da LLM (prompts, contexto, resposta bruta, notas, juiz, tokens) e a avaliação salva. Um seletor offline/groq permite navegar sem gastar a cota; a chave da LLM fica só no servidor.
- A implantação em nuvem é opcional no enunciado; os manifestos Kubernetes funcionam em qualquer cluster gerenciado (EKS, GKE, AKS).

9. Organização do código e testes

Projeto Python com Poetry (pyproject.toml) ou venv (requirements.txt), código em src/, scripts de execução em scripts/, configuração em configs/ e notebook de demonstração em notebooks/02_demo_fase2.ipynb. Os testes automatizados (pytest, pasta tests/) cobrem:

- codificação e decodificação dos genes, operadores de seleção, cruzamento e mutação;
- o motor do AG: convergência num problema de referência, elitismo monotônico, reprodutibilidade por semente, cache, parada antecipada, semeadura e tolerância a falhas da fitness;
- dados (split idêntico à Fase 1), modelos, limiar e fitness (inclusive o reaproveitamento sem re-treino);
- LLM: contexto, prompts, extração de JSON, fallback, e os critérios de avaliação (números inventados, linguagem proibida, cobertura e coerência);
- API: health/ready, previsão, validação de entrada, interpretação, perguntas, métricas e job do AG;
- rotas da aplicação web (pacientes, inspeção da LLM, avaliações, convergência) e o contrato das rotas antigas (sem resposta bruta nem prompts);
- provedores: novas tentativas em 429/timeout, erro imediato sem chave, leitura do .env e modelos de raciocínio com esforço baixo.

10. Desafios enfrentados e soluções

Desafio	Solução
Hiperparâmetros de tipos diferentes no mesmo cromossomo	Codificação real normalizada com genes tipados
Custo computacional do Random Forest com CV	Cache de fitness, reaproveitamento das probabilidades quando só o limiar muda e faixa de n_estimators ajustada
Risco de sobreajustar ao teste	AG só no treino; seleção pela CV repetida; teste usado uma vez
Fitness quase saturada (~0,97) e roleta pouco seletiva	Roleta com deslocamento pelo mínimo e comparação com torneio e ranking
Solução trivial "tudo maligno" ao otimizar recall	F1 e AUC na fitness
API depreciou penalty na Regressão Logística (scikit-learn ≥ 1.8)	Uso de l1_ratio com verificação de versão
LLM pode inventar números ou dar diagnóstico definitivo	Grounding, regras no prompt e avaliação automática de fidelidade e segurança
LLM indisponível ou resposta fora do formato	Validação do JSON e fallback por template, monitorado
Atributos correlacionados geram contribuições contraintuitivas na oclusão	Contexto inclui as médias por classe para o médico interpretar; documentado como limitação

11. Limitações e próximos passos

- Dataset público e pequeno (569 amostras); antes de qualquer uso assistencial é necessária validação externa e prospectiva com dados do hospital.
- Os pesos da fitness refletem uma preferência por recall que deve ser definida com a equipe clínica.
- Explicações locais por oclusão não tratam a correlação entre atributos (ex.: raio, perímetro e área).
- Próximos passos (Módulo 3): ampliar o espaço de busca (seleção de atributos, outros algoritmos), otimização multiobjetivo (NSGA-II) para a fronteira recall x falsos positivos, integrar laudos textuais ao contexto da LLM e levar as explicações para o fluxo de atendimento (a aplicação web desta fase é uma ferramenta de demonstração e conferência, não um produto clínico).

12. Como reproduzir

```
git clone https://github.com/Gusta2150/desafio_tech_2.git && cd desafio_tech_2
python -m venv .venv && source .venv/bin/activate   # Windows: .venv\Scripts\activate
pip install -r requirements.txt                     # ou: poetry install
python -m scripts.run_experiments                   # AG: todos os experimentos
python -m scripts.evaluate_llm --provider groq      # avaliação da LLM (GROQ_API_KEY no .env)
python -m scripts.make_figures && python -m scripts.generate_report
pytest                                              # testes
uvicorn src.api.main:app --port 8000                # API em http://localhost:8000/docs
cd frontend && npm install --legacy-peer-deps && npm start   # app web em http://localhost:4201
```

Repositório: https://github.com/Gusta2150/desafio_tech_2